

Rapport de Travaux Pratiques : Analyse des Notes et Taux d' Absence

1. Introduction et Contexte du TP

Ce rapport détaille les travaux pratiques (TP) menés sur l'analyse des notes d'élèves en fonction de leur taux de présence, dans le but de prédire leur filière (littéraire ou scientifique) au sein d'une classe de terminale. L'objectif principal est de comprendre les relations entre ces variables et de développer un modèle de classification.

Le TP se décompose en plusieurs étapes clés : la génération de données synthétiques, une étude statistique univariée, une étude bivariée avec régression linéaire, et enfin, une classification non supervisée suivie d'une critique du modèle.

2. Structure du Projet et Flux de Données

Pour organiser efficacement les travaux de ce TP, une structure de projet standardisée a été adoptée. Cette organisation permet de séparer clairement les différentes étapes du processus d'analyse de données, de la génération à la modélisation.

```
INF232_TP_GROUPE20t/
├── data/
│   ├── raw/           # Données brutes générées (jamais modifiées)
│   ├── interim/       # Données en cours de traitement
│   └── processed/     # Données finales prêtes pour le modèle
├── notebooks/        # Analyses statistiques exploratoires (Jupyter)
├── src/              # Code source du projet
│   ├── data/         # Scripts de génération et chargement
│   ├── features/      # Scripts de transformation des variables
│   ├── models/       # Scripts d'apprentissage supervisé et évaluation
│   └── utils/        # Votre fonction clé et votre générateur naïf
├── reports/         # Rapports d'étude
└── figures/         # Graphiques statistiques sauvegardés
```

2.1. Explication des Dossiers et Flux de Données

Chaque dossier a un rôle spécifique dans le cycle de vie du projet et gère un type de données ou de code particulier :

- **data/** : Ce dossier centralise toutes les données utilisées et générées par le projet. Il est subdivisé pour suivre le cycle de vie des données :
 - **raw/** : Contient les données brutes initialement générées. Dans le cadre de ce TP, ce sont les données synthétiques créées à partir de la graine SHA-256. Ces données ne doivent jamais être modifiées après leur génération initiale.
 - **interim/** : Stocke les données qui ont subi une première étape de nettoyage ou de transformation, mais qui ne sont pas encore prêtes pour l'entraînement des modèles. Par exemple, après une imputation de valeurs manquantes ou une agrégation préliminaire.
 - **processed/** : Contient les jeux de données finaux, entièrement nettoyés, transformés et prêts à être utilisés pour l'entraînement et l'évaluation des modèles. C'est l'entrée principale pour les scripts de modélisation.
- **notebooks/** : Ce dossier est dédié aux analyses exploratoires de données (EDA) et aux expérimentations. Les fichiers Jupyter Notebook (`.ipynb`) y sont stockés. C'est ici que les études statistiques univariées (Question 1) et bivariées (Question 2) sont initialement développées et visualisées. Les sorties graphiques de ces notebooks sont ensuite sauvegardées dans `reports/figures/` .
- **src/** : Ce dossier contient tout le code source du projet, organisé par fonctionnalité pour une meilleure maintenabilité et réutilisabilité. C'est le cœur de l'implémentation des différentes étapes du TP :
 - **data/** : Inclut les scripts Python responsables de la génération des données synthétiques (comme décrit dans la Section 3.1 du rapport) et du chargement des données depuis les différents sous-dossiers de `data/` .
 - **features/** : Contient les scripts pour la création de nouvelles variables (ingénierie de caractéristiques) ou la transformation des variables existantes, par exemple, la normalisation ou la standardisation des notes et taux de présence.
 - **models/** : Regroupe les scripts pour la construction, l'entraînement, l'évaluation et la persistance des modèles d'apprentissage automatique (régression linéaire pour la Question 2, et les modèles de clustering pour la Question 3).
 - **utils/** : Ce dossier est destiné aux fonctions utilitaires génériques qui peuvent être utilisées à travers différents modules du projet, comme la fonction clé de génération de graine ou d'autres outils d'aide à la manipulation des données.
- **reports/** : Ce dossier est destiné à stocker les rapports d'étude, les présentations et autres documents finaux du projet. Le présent rapport PDF serait un exemple de fichier stocké ici.

- **figures/** : Contient toutes les figures et graphiques générés lors des analyses (notamment depuis les notebooks) et utilisés dans les rapports. Par exemple, les boîtes à moustaches de la Question 1 ou les visualisations des clusters de la Question 3.

2.2. Flux de Données et Intégration au TP

Le flux de données suit une logique séquentielle et structurée :

1. **Génération** : Les scripts de `src/data/` génèrent les données brutes qui sont sauvegardées dans `data/raw/`.
2. **Exploration et Prétraitement** : Les notebooks dans `notebooks/` chargent les données de `data/raw/`, effectuent des analyses exploratoires, et les scripts de `src/features/` transforment ces données. Les résultats intermédiaires peuvent être sauvegardés dans `data/interim/`.
3. **Préparation Finale** : Les données prêtes pour la modélisation sont déplacées ou sauvegardées dans `data/processed/`.
4. **Modélisation** : Les scripts de `src/models/` chargent les données de `data/processed/` pour entraîner les modèles de régression et de clustering. Les résultats des modèles (prédictions, évaluations) sont générés.
5. **Rapports et Visualisations** : Les figures générées par les notebooks ou les scripts de modélisation sont sauvegardées dans `reports/figures/`. Le rapport final, intégrant toutes les analyses et conclusions, est compilé dans `reports/`.

Cette structure assure une traçabilité claire des données et du code, facilitant la collaboration et la reproductibilité des analyses.

3. Génération des Données Synthétiques

Pour ce TP, un jeu de données synthétique a été créé afin de simuler des scénarios réels d'évaluation et de présence. La génération de ces données repose sur des principes spécifiques pour assurer leur pertinence et leur réalisme.

3.1. Génération de la Graine (Seed)

La reproductibilité des résultats est assurée par l'utilisation d'une graine (seed) pour le générateur de nombres aléatoires. Cette graine est dérivée du nom du chef de groupe, transformé selon le processus suivant :

1. **Normalisation du nom** : Le nom du chef de groupe est nettoyé (suppression des accents, conversion en majuscules).

2. **Hachage SHA-256** : La chaîne de caractères normalisée est soumise à l'algorithme de hachage SHA-256, produisant une valeur hexadécimale.
3. **Conversion en entier 16 bits** : Cette valeur hexadécimale est ensuite convertie en un entier sur 16 bits, qui sert de graine pour les fonctions de génération de nombres aléatoires de NumPy.

3.2. Génération des Variables X et Y

Deux variables principales sont générées à l'aide de la bibliothèque NumPy :

- **Variable X (Notes d'évaluation)** : Représente les notes obtenues par les élèves lors d'un examen. Ces valeurs sont générées aléatoirement et sont comprises entre 0 et 20.
- **Variable Y (Taux de présence)** : Représente le taux de présence des élèves aux cours de mathématiques. Ces valeurs sont générées aléatoirement et sont exprimées en pourcentage, comprises entre 0 % et 100 %.

3.3. Relation entre X et Y et Introduction de Bruit

Afin de faciliter l'étude statistique et de simuler une certaine corrélation, les variables X et Y sont rendues approximativement proportionnelles. Pour certaines valeurs, la relation est définie par $Y = 5 * X$. Cette proportionnalité est ajustée pour tenir compte des échelles différentes (X sur 20, Y sur 100).

Pour introduire du réalisme et éviter une corrélation parfaite, du **bruit** est ajouté à certaines données. Ce bruit se manifeste par des valeurs aberrantes qui ne respectent pas strictement la relation $Y = 5 * X$, rendant le jeu de données plus proche d'une situation réelle.

3.4. Génération de la Variable Cible (Target)

La variable cible, qui indique la filière de l'élève (scientifique ou littéraire), est générée à partir d'un ratio entre les variables X et Y. Ce ratio permet de créer une distinction entre les deux groupes, servant de base pour les tâches de classification ultérieures.

4. Étude Statistique Univariée (Question 1)

La première étape de l'analyse consiste en une étude statistique univariée de la variable X (notes d'évaluation). Cette analyse sera réalisée à l'aide de la bibliothèque Pandas pour obtenir des statistiques descriptives et de Matplotlib pour la visualisation.

4.1. Statistiques Descriptives

Les statistiques descriptives suivantes seront calculées pour la variable X :

- **Moyenne** : Mesure de la tendance centrale.
- **Écart-type** : Mesure de la dispersion.
- **Quartiles** : Q1 (25ème percentile), Q2 (médiane, 50ème percentile), Q3 (75ème percentile), permettant de comprendre la distribution des notes.
- **Minimum et Maximum** : Les valeurs extrêmes observées.

4.2. Visualisation : Boîte à Moustaches (Box Plot)

Une boîte à moustaches sera tracée à l'aide de Matplotlib pour visualiser la distribution des notes. Cet outil graphique permet d'identifier rapidement la médiane, les quartiles, l'étendue interquartile et les valeurs aberrantes (outliers) de la variable X .

5. Étude Bivariée et Régression Linéaire (Question 2)

Cette section se concentre sur l'analyse de la relation entre deux variables et la prédiction.

5.1. Étude Bivariée

Une étude bivariée sera menée entre la variable Y (taux de présence aux cours de mathématiques) et la variable X (note de mathématiques). Cette analyse permettra de déterminer la nature et la force de la relation entre l'assiduité et la performance scolaire.

5.2. Régression Linéaire

L'objectif est de prédire la variable X (note de mathématiques) à partir de la variable Y (taux de présence). Un modèle de régression linéaire sera construit pour modéliser cette relation. L'équation de la droite de régression et les coefficients associés seront déterminés, permettant de quantifier l'impact du taux de présence sur la note.

6. Classification Non Supervisée (Question 3)

La troisième question du TP vise à construire un modèle de classification non supervisée pour la variable cible (filière scientifique ou littéraire) en utilisant les variables X et Y .

6.1. Choix du Modèle de Clustering

Plusieurs algorithmes de clustering pourront être envisagés, tels que :

- **K-Means** : Un algorithme populaire pour partitionner les données en un nombre k de clusters.

- **K-Nearest Neighbors (KNN)** : Bien que principalement un algorithme supervisé, il peut être adapté pour des tâches de classification basées sur la proximité.
- **Support Vector Machine (SVM)** : Principalement supervisé, mais des variantes peuvent être utilisées pour la détection d'anomalies ou le clustering.

Le choix final dépendra de la structure des données et des objectifs spécifiques de la classification. L'objectif est de regrouper les élèves en fonction de leurs notes et de leur taux d'absentéisme pour identifier des profils types (par exemple, un cluster pour les élèves de filière littéraire et un autre pour les scientifiques).

6.2. Interprétation des Clusters

Une fois les clusters formés, une analyse sera effectuée pour interpréter les caractéristiques de chaque groupe. Par exemple, un cluster pourrait regrouper des élèves avec des notes élevées et un faible taux d'absence (profil scientifique), tandis qu'un autre pourrait correspondre à des notes plus faibles et un taux d'absence plus élevé (profil littéraire, ou nécessitant un soutien).

7. Critique et Mise à Jour du Modèle (Question 4)

La dernière étape du TP consiste à critiquer le modèle de classification développé et à discuter de sa pertinence pour l'orientation des élèves.

7.1. Critique du Modèle

La critique portera sur :

- **Performance du clustering** : Évaluation de la qualité des clusters (cohérence interne, séparation entre les clusters).
- **Robustesse** : Capacité du modèle à généraliser à de nouvelles données.
- **Limitations** : Identification des biais potentiels ou des facteurs non pris en compte qui pourraient influencer les résultats.

7.2. Recommandations pour la Mise à Jour et l'Orientation

Des recommandations seront formulées concernant la mise à jour et l'amélioration du modèle. Il sera également discuté de la confiance que l'on peut accorder à ce modèle pour l'orientation des élèves. Cela inclura des suggestions sur l'intégration de variables supplémentaires, l'utilisation d'algorithmes plus sophistiqués, ou la nécessité d'une validation externe pour renforcer la fiabilité du système d'orientation basé sur ce modèle.

8. Conclusion

Ce TP fournit une approche complète de l'analyse des données scolaires, de la génération de données à la modélisation prédictive et classificatoire. Les résultats obtenus permettront de mieux comprendre les dynamiques entre les notes et l'assiduité, et d'explorer des pistes pour l'orientation des élèves. Les étapes futures incluront l'implémentation concrète de ces analyses et la validation des modèles sur des données réelles, si disponibles.