

epstopdf-baseRedefining graphics rule for ‘.eps’ grfextGraphics extension search list:[.pdf,.png,.jpg,.m

Université de Yaoundé I — INF232

TP : Analyse des performances scolaires

Rapport Global — Groupe 20

L2 Informatique

Chef de groupe : Atangana Abogo Emmanuel (23V2348)

Graine reproductible : 1021

Membre	Matricule
Samaki Nya Zenouba Rhyade	24G2773
TCHATCHOUANG TANKIO GRÂCE FARELLE	24F2749
TSIADZE DONFACK DARLENE	24G2361
Atangana Abogo Emmanuel	23V2348
BISSEMOU FRANCKY DILANE	24F2628
MINKAM TEDONFOUE KELLY DOLVIANE	24G2883
TCHUITCHEU WOUATCHUI FLORES BACKER	24F2779
YATIÉ WANTED Wendy Elvira	23U2749

Date : July 5, 2026

Contents

1	Introduction	2
1.1	Contexte	2
1.2	Structure du projet	2
2	Données synthétiques	3
3	Question 1 : Répartition des notes	4
4	Question 2 : Lien assiduité–note et régression	5
4.1	Volet 1 : analyse bivariée	5
4.2	Volet 2 : régression linéaire (modèle retenu)	5
5	Question 3 : Profils d’élèves (K-Means)	7
5.1	Pourquoi le non supervisé ?	7
6	Question 4 : Suggestion automatique d’orientation	9
7	Conclusion	11

Chapter 1

Introduction

1.1 Contexte

Un établissement secondaire dispose pour chaque élève de terminale :

- une **note** à l'évaluation interne de mathématiques (/20) ;
- un **taux d'assiduité** aux cours de maths (%) ;
- une **orientation** recommandée (littéraire = 0, scientifique = 1).

Le proviseur pose **quatre questions**. Nous y répondons avec des méthodes du cours, en langage simple.

1.2 Structure du projet

Conformément aux consignes (`reports/instructions_TP.pdf`), le dépôt suit le cycle : `data/raw` $\rightarrow$ `data/interim/processed` $\rightarrow$ `src/models` $\rightarrow$ `reports/figures`. Tout est rejouable avec `python main.py`.

Chapter 2

Données synthétiques

Graine : dérivée du nom du chef de groupe via SHA-256 (`src/utils/graine.py`), valeur **1021**.

Génération (`src/data/generateur.py`) :

```
X = notes uniformes entre 0 et 20
Y = clip(5 * X + bruit, 0, 100)
target = 1 si Assidueite >= 50% else 0
```

Jeu produit : 1000 élèves, 491 scientifiques (49,1%), 509 littéraires (50,9%). Le fichier `data/raw/donnees.csv` n'est jamais modifié après génération.

Chapter 3

Question 1 : Répartition des notes

Question : Comment se répartissent les notes ? Y a-t-il des élèves atypiques ?

Méthode : analyse univariée (moyenne, quartiles, règle de Tukey pour les outliers).

Script : `src/models/analyse_univariee.py`

```
borne_basse = q1 - 1.5 * iqr
```

```
borne_haute = q3 + 1.5 * iqr
```

```
outliers = notes[(notes < borne_basse) | (notes > borne_haute)]
```

Table 3.1: Statistiques des notes

Moyenne	10,00 /20
Médiane	9,8 /20
Écart-type	5,67
Outliers (Tukey)	0




Figure 3.1: Boîte à moustaches des notes

Réponse : distribution symétrique, aucun outlier statistique. Pour le conseil pédagogique, présenter la boîte à moustaches avec la médiane (9,8/20).

Chapter 4

Question 2 : Lien assiduité–note et régression

Question : Le résultat est-il lié à l'assiduité ? Peut-on anticiper la note ?

4.1 Volet 1 : analyse bivariée

```
pearson = df["Assiduite"].corr(df["Notes"])  
spearman = df["Assiduite"].corr(df["Notes"], method="spearman")
```

Résultat : Pearson $r = 0,985$ — lien linéaire très fort, confirmé visuellement.




Figure 4.1: Nuage de points Assiduité vs Notes

4.2 Volet 2 : régression linéaire (modèle retenu)

Pourquoi la régression linéaire ?

1. Le nuage de points montre une relation quasi linéaire ($r = 0,985$).
2. Équation lisible pour le proviseur : $+10\%$ d'assiduité $\approx +2$ pts de note.
3. Meilleure performance sur le jeu de test (RMSE = 1,041 pt, $R^2 = 0,966$).
4. Conforme aux consignes du TP (Section 5 : régression linéaire).

Trois modèles comparés ; KNN et SVR n'apportent pas de gain significatif.

```
modeles = {
    "Regression lineaire": LinearRegression(),
    "KNN (k=5)": KNeighborsRegressor(n_neighbors=5),
    "SVR (RBF)": SVR(kernel="rbf"),
}
```

Table 4.1: Comparaison des modèles (test, n=200)

Modèle	RMSE	MAE	R^2
Régression linéaire	1,041	0,827	0,966
SVR (RBF)	1,052	0,842	0,965
KNN ($k = 5$)	1,108	0,888	0,961

Équation retenue : Notes $\approx 0,20 \times$ Assiduité $+0,28$.

Seuil d'incertitude : RMSE < 2 pts $\Rightarrow$ anticipation utilisable avec prudence. Notre RMSE = 1,04 pt, donc en dessous du seuil, mais ne remplace pas l'évaluation réelle.

Chapter 5

Question 3 : Profils d'élèves (K-Means)

Question : Des groupes naturels apparaissent-ils, indépendamment de l'orientation ?

5.1 Pourquoi le non supervisé ?

- Le proviseur demande des profils **sans** utiliser l'orientation du conseil de classe.
- En **supervisé**, le modèle reproduirait la décision déjà prise (variable **target**).
- En **non supervisé** (K-Means), on découvre des groupes à partir de Notes et Assiduité seules.
- KNN et SVM sont supervisés : ils conviennent à la Q4, pas à la Q3.

```
features = df[["Notes", "Assiduite"]]  
X_scaled = StandardScaler().fit_transform(features)  
kmeans = KMeans(n_clusters=3, random_state=42)  
df["cluster"] = kmeans.fit_predict(X_scaled)
```

Choix de $K = 3$: méthode du coude + score de silhouette ($\sim 0,58$, le meilleur).

Table 5.1: Trois profils identifiés

Profil	Note moy.	Assid. moy.	Effectif
Fragile	3,5 /20	16,7 %	330
Intermédiaire	9,9 /20	49,4 %	337
Solide	16,6 /20	82,5 %	333

Réponse : 3 profils distincts pour un accompagnement différencié (soutien, consolidation, approfondissement), en complément de l'orientation officielle.




Figure 5.1: Visualisation des 3 clusters

Chapter 6

Question 4 : Suggestion automatique d'orientation

Question : Peut-on suggérer une filière avant la délibération ? Quelle confiance accorder ?

Ici on utilise l'**apprentissage supervisé** : on prédit `target` à partir de Notes et Assiduité.

```
X = df[["Notes", "Assiduite"]]  
y = df["target"]  
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.2, stratify=y)
```

Trois classifieurs comparés : régression logistique, KNN ($k = 5$), SVM (RBF).

Table 6.1: Résultats classification (test, n=200)

Modèle	Précision	F1
Régression logistique	100 %	1,000
KNN ($k = 5$)	100 %	1,000
SVM (RBF)	100 %	1,000

Attention : 100 % de précision ne signifie pas que le système est fiable en réel. La cible a été générée par la règle **Assiduité** $\geq 50\%$; le modèle apprend cette règle artificielle. L'orientation réelle dépend aussi du français, de la philosophie, des entretiens.

Risques pédagogiques : stéréotypes (assiduité = scientifique), profils atypiques mal classés, décision sans jugement humain.

Réponse : utilisable comme **aide à la discussion** au conseil de classe, jamais comme décision automatique.




Figure 6.1: Matrice de confusion (régression logistique)

Chapter 7

Conclusion

Table 7.1: Synthèse des quatre questions

Q1	Médiane 9,8/20, 0 outlier, boîte à moustaches recommandée
Q2	$r = 0,985$, régression linéaire (RMSE 1,04 pt), anticipation prudente
Q3	3 profils K-Means (fragile, intermédiaire, solide)
Q4	Précision 100 % mais risque pédagogique : ne pas automatiser

Recommandations : croiser notes, assiduité et entretiens ; ne jamais remplacer le conseil de classe ; relancer `python main.py` pour reproduire les résultats.