

RÉPUBLIQUE DU CAMEROUN


Paix – Travail – Patrie

REPUBLIC OF CAMEROON

Peace – Work – Fatherland

UNIVERSITÉ DE YAOUNDÉ I
FACULTÉ DES SCIENCES
DÉPARTEMENT D'INFORMATIQUE

UNIVERSITY OF YAOUNDE I
FACULTY OF SCIENCE
DEPARTMENT OF COMPUTER
SCIENCE



INF232 : ANALYSE DE DONNÉES ET STATISTIQUES

THÈME D

Analyse des notes et de l'assiduité des élèves de terminale

Informations des étudiant(e)s

Nom

Matricule

Atangana Abogo Emmanuel	23V2348
Samaki Nya Zenouba Rhyade	24G2773
Tchatchouang Tankio Grâce Farelle	24F2749
Tsiadze Donfack Darlene	24G2361
Bissemou Francky Dilane	24F2628
Minkam Tedonfoue Kelly Dolviane	24G2883
Tchuitcheu Wouatchui Flores Backer	24F2779
Yatié Wantem Wendy Elvira	23U2749
FOUGA FOUGA GEORGINE	24G2137
OREME MARIE THERESE	23V2326

Dépôt GitHub

https://github.com/ABOGO-tech237/INF232_TP_GROUPE20

Sous la direction de :

Dr. NZEKON NZEKO'O Armel Jacques

Année Académique : 2025-2026

Table des matières

1	Introduction et contexte	3
1.1	Variables retenues	3
1.2	Génération reproductible des données	3
2	Structure du projet	4
3	Question 1 – Répartition des notes	4
3.1	Question posée	4
3.2	Notions du cours mobilisées et méthode	4
3.3	Résultats	5
3.4	Interprétation pour le conseil pédagogique	6
3.5	Limites et discussion	6
4	Question 2 – Lien assiduité/note et prédiction	6
4.1	Question posée	6
4.2	Volet 1 – Vérifier le lien	6
4.2.1	Notions mobilisées	6
4.3	Volet 2 – Pourquoi la régression linéaire ?	7
4.3.1	Équation retenue	8
4.4	Seuil d’incertitude acceptable	8
4.5	Limites et discussion	8
5	Question 3 – Profils d’élèves (clustering)	9
5.1	Question posée	9
5.2	Pourquoi l’apprentissage <i>non supervisé</i> et pas du supervisé ?	9
5.3	Choix du nombre de clusters K	9
5.4	Résultats – 3 profils	10
5.5	Limites et discussion	11
6	Question 4 – Suggestion automatique d’orientation	11
6.1	Question posée	11
6.2	Pourquoi l’apprentissage <i>supervisé</i> ici (contraste avec Q3)	11
6.3	Modèles comparés	11
6.4	Résultats	12
6.5	Est-ce raisonnable ? Quelle confiance et quel risque ?	13
6.6	Recommandation	13
7	Synthèse pour le proviseur	14
7.1	Recommandations générales	14

1 Introduction et contexte

La direction d'un établissement scolaire secondaire souhaite mieux comprendre les performances et les profils de ses élèves de terminale à partir des résultats d'une évaluation interne. Elle pose quatre questions concrètes auxquelles ce travail répond par des méthodes issues du cours d'INF232.

1.1 Variables retenues

Variable	Symbole	Justification
Note d'évaluation	Notes (X)	Mesure directe de la performance en mathématiques, sur 20
Taux de présence	Assiduité (Y)	Indicateur de régularité et de travail personnel, en %
Orientation	target	Décision déjà prise par le conseil de classe (0 = littéraire, 1 = scientifique)

Tableau 1: Variables du jeu de données synthétique

La relation imposée à la génération ($Y \approx 5X$) reflète une intuition pédagogique raisonnable : un élève assidu tend à obtenir une meilleure note. Un bruit gaussien est ajouté pour éviter une corrélation parfaite et produire des profils atypiques réalistes.

1.2 Génération reproductible des données

La reproductibilité est assurée par une graine dérivée du nom du chef de groupe, via un hachage SHA-256 :

```
1 def nettoyer_texte(texte: str) -> str:
2     """Normalise : suppression des accents, majuscules."""
3     texte = texte.strip()
4     sans_accents = unicodedata.normalize("NFKD", texte)
5     sans_accents = "".join(c for c in sans_accents
6                             if not unicodedata.combining(c))
7     return sans_accents.upper()
8
9 def generer_graine(texte: str) -> int:
10     texte_normalise = nettoyer_texte(texte)
11     hash_hex = hashlib.sha256(texte_normalise.encode()).hexdigest()
12     return int(hash_hex, 16) % (2 ** 12)
```

Avec le nom correct "Atangana Abogo Emmanuel", la graine obtenue est **1292** (contre 14 avec l'ancienne orthographe erronée – deux graines totalement différentes, ce qui confirme qu'il fallait régénérer l'ensemble des résultats).

```
1 X = rng.uniform(0, 20, 1000)           # Notes, arrondies a 0.1
2 bruit = rng.normal(0, 5, 1000)
3 Y = np.clip(5 * X + bruit, 0, 100)      # Assiduite
4 target = (Y >= 50).astype(int)         # 1 = scientifique
```

Nombre d'élèves	1000
Orientation scientifique (1)	493 (49,3%)
Orientation littéraire (0)	507 (50,7%)

Tableau 2: Jeu de données régénéré (data/raw/donnees.csv)

Règle du projet : le fichier `data/raw/donnees.csv` n'est jamais modifié après sa génération ; toutes les transformations produisent des fichiers dans `data/interim/` ou `data/processed/`.

2 Structure du projet

Le projet suit une architecture modulaire classique en science des données, séparant strictement code, données et résultats :

```
1 INF232_TP_GROUPE20/
2 |-- data/
3 |   |-- raw/           # Donnees brutes generees (jamais modifiees)
4 |   |-- interim/       # Resultats intermediaires (stats, CSV)
5 |   +-- processed/     # Donnees finales pretes pour modelisation
6 |-- notebooks/        # Explorations interactives (Jupyter)
7 |-- src/
8 |   |-- utils/         # Graine SHA-256
9 |   |-- data/          # Generation et chargement
10 |   |-- features/      # Standardisation
11 |   +-- models/       # Un script par question
12 |-- reports/
13 |   +-- figures/       # Graphiques pour le rapport
14 +-- main.py           # Orchestration de bout en bout
```

Justification de cette organisation :

- **Séparation données/code** : `data/raw` n'est jamais écrasé, ce qui garantit qu'on peut toujours revenir au jeu de données d'origine et vérifier la reproductibilité (même graine $\Rightarrow$ mêmes données).
- **Un script = une question** : chaque question du proviseur correspond à un fichier autonome dans `src/models/`, ce qui facilite la relecture, le test et la correction indépendante de chaque partie.
- **data/interim vs data/processed** : distingue les résultats de calcul intermédiaires (statistiques, matrices de corrélation) des données réellement transformées et prêtes pour un modèle (ex. : jeu enrichi avec les clusters).
- **main.py** centralise l'orchestration pour garantir que `python main.py` rejoue l'intégralité de l'analyse dans le bon ordre (génération $\rightarrow$ Q1 $\rightarrow$ Q2 $\rightarrow$ Q3 $\rightarrow$ Q4), condition indispensable de reproductibilité exigée par le sujet.

3 Question 1 – Répartition des notes

3.1 Question posée

« Comment se répartissent les résultats de mes élèves ? Y a-t-il des élèves dont le résultat sort vraiment de l'ordinaire ? Comment présenter cela simplement au conseil pédagogique, qui n'est pas formé en statistique ? »

3.2 Notions du cours mobilisées et méthode

Il s'agit d'une **analyse statistique univariée** : une seule variable est étudiée (**Notes**), sans tenir compte des autres. On utilise :

- les **statistiques descriptives** (moyenne, écart-type, quartiles) pour résumer la distribution ;

- la **règle de Tukey** pour détecter les valeurs atypiques (outliers), car elle est robuste, simple à expliquer et ne suppose pas que les données suivent une loi particulière (contrairement à une règle basée sur l'écart-type, plus sensible aux valeurs extrêmes qu'elle est censée détecter).

```

1 q1, q3 = notes.quantile(0.25), notes.quantile(0.75)
2 iqr = q3 - q1
3 borne_basse = q1 - 1.5 * iqr
4 borne_haute = q3 + 1.5 * iqr
5 outliers = notes[(notes < borne_basse) | (notes > borne_haute)]

```

3.3 Résultats

Moyenne	9,90 /20
Écart-type	5,87
Q1 (25%)	4,80
Médiane (Q2)	9,75
Q3 (75%)	15,10
Minimum / Maximum	0,0 / 20,0
IQR	10,30
Bornes de Tukey	[−10,65 ; 30,55]
Outliers détectés	0

Tableau 3: Statistiques descriptives des notes (graine corrigée 1292)




Figure 1: Boîte à moustaches des notes




Figure 2: Histogramme des notes

3.4 Interprétation pour le conseil pédagogique

La médiane (9,75) est très proche de la moyenne (9,90), ce qui indique une distribution **à peu près symétrique**. L'écart-type élevé (5,87) montre que les notes sont étalées sur toute l'échelle 0–20. Comme les bornes de Tukey (−10,65 et 30,55) dépassent largement l'intervalle possible des notes ([0,20]), **aucune note, même 0 ou 20, n'est statistiquement aberrante** : ce sont des valeurs extrêmes mais plausibles dans une distribution uniforme, pas des anomalies.

3.5 Limites et discussion

- La règle de Tukey suppose implicitement une distribution unimodale ; ici la distribution est proche de l'uniforme.
- L'absence d'outliers statistiques ne signifie pas l'absence d'élèves en difficulté : un élève à 2/20 n'est pas un « outlier » mais mérite un suivi pédagogique.

4 Question 2 – Lien assiduité/note et prédiction

4.1 Question posée

« Le résultat est-il fortement lié à l'assiduité ? Peut-on anticiper la note des élèves n'ayant pas encore passé l'évaluation ? À partir de quel point l'anticipation devient-elle trop incertaine ? »

4.2 Volet 1 – Vérifier le lien

4.2.1 Notions mobilisées

On mesure la force du lien entre deux variables quantitatives avec les **coefficients de corrélation de Pearson et de Spearman**, et la **covariance**.

```
1 pearson = df["Assiduite"].corr(df["Notes"], method="pearson")
2 spearman = df["Assiduite"].corr(df["Notes"], method="spearman")
3 covariance = np.cov(df["Assiduite"], df["Notes"])[0, 1]
```

Indicateur	Valeur	Interprétation
Pearson (r)	0,986	Lien linéaire très fort
Spearman (ρ)	0,986	Lien monotone très fort, robuste aux outliers
Covariance	169,68	Forte co-variation

Tableau 4: Indicateurs bivariés (données recalculées, graine 1292)




Figure 3: Nuage de points Assiduité vs Notes

Le nuage de points confirme visuellement une relation **quasi linéaire** : les points s’alignent sur une droite croissante, sans courbure marquée.

4.3 Volet 2 – Pourquoi la régression linéaire ?

Justification du choix de la régression linéaire (et pas une autre méthode comme premier modèle de référence) :

1. Le **processus de génération** des données impose une relation $Y \approx 5X + \varepsilon$: la structure sous-jacente est linéaire par construction.
2. Le **nuage de points** et le coefficient de Pearson ($r = 0,986$, très proche de la corrélation de Spearman) confirment que la relation est linéaire et pas seulement monotone : si la relation avait été monotone mais courbe, Spearman serait significativement supérieur à Pearson, ce qui n’est pas le cas ici.
3. La régression linéaire est **directement interprétable** par un non statisticien : l’équation $\text{Notes} = a \times \text{Assiduité} + b$ peut se traduire en phrase simple (« chaque point d’assiduité supplémentaire ajoute environ 0,2 point de note »), contrairement à un modèle KNN ou SVR qui sont des boîtes plus opaques.
4. Elle sert de **modèle de référence** auquel on compare des méthodes plus flexibles (KNN, SVR) pour vérifier si la flexibilité supplémentaire apporte un vrai gain de précision, ou si elle complexifie inutilement le modèle pour un gain marginal.

```

1 X_train, X_test, y_train, y_test = train_test_split(
2   X, y, test_size=0.2, random_state=42)    # 800 / 200 élèves
3

```

```

4 lr = LinearRegression().fit(X_train, y_train)
5 knn = KNeighborsRegressor(n_neighbors=5).fit(X_train_scaled, y_train)
6 svr = SVR(kernel="rbf").fit(X_train_scaled, y_train)

```

KNN et SVR nécessitent une **standardisation** préalable (**StandardScaler**) car ce sont des méthodes basées sur des distances ou des noyaux, sensibles à l'échelle des variables ; la régression linéaire n'en a pas besoin.

4.3.1 Équation retenue

$$\text{Notes} \approx 0,198 \times \text{Assiduité} + 0,009 \quad (1)$$

Interprétation : +10 points d'assiduité $\Rightarrow$ environ +2 points de note.




Figure 4: Prédications du meilleur modèle sur le jeu de test

4.4 Seuil d'incertitude acceptable

Critère retenu : une anticipation est jugée trop incertaine si la RMSE dépasse **2 points sur 20** (10% de la note maximale), seuil au-delà duquel l'erreur devient trop grande pour fonder une décision individuelle.

Situation	RMSE	Décision
Nos données	1,02 pt	Anticipation utilisable, avec prudence
Seuil limite	2,0 pts	Au-delà, ne pas fonder une décision seule

4.5 Limites et discussion

- La relation testée ici est **univoque et synthétique** : dans un établissement réel, l'assiduité seule n'explique jamais 97% de la variance des notes ; d'autres facteurs (méthode de travail, soutien familial, matière) interviennent.
- Le modèle prédit une **note moyenne probable**, pas une certitude individuelle : deux élèves à la même assiduité peuvent avoir des notes différentes (le bruit gaussien du modèle de génération le montre).
- Extrapoler en dehors de la plage observée (assiduité proche de 0% ou de 100%) est risqué, la régression linéaire n'étant fiable que dans l'intervalle des données d'entraînement.

5 Question 3 – Profils d'élèves (clustering)

5.1 Question posée

« Indépendamment de l'orientation déjà recommandée, mes données font-elles apparaître des groupes d'élèves aux profils proches ? Combien de profils distincts, et comment les décrire ? »

5.2 Pourquoi l'apprentissage *non supervisé* et pas du supervisé ?

C'est un point de méthode important, qu'il faut justifier explicitement :

- L'apprentissage **supervisé** exige une **variable cible connue** que l'on cherche à prédire (ex. : Q2 prédit **Notes**, Q4 prédira **target**). Or, la question 3 ne demande **pas** de prédire l'orientation : elle demande de découvrir des **regroupements naturels** d'élèves, sans utiliser cette étiquette, justement pour voir si les données *elles-mêmes* suggèrent une structure, avant toute décision.
- Utiliser **target** pour construire les groupes reviendrait à **recopier une décision déjà prise** par le conseil de classe, ce qui ne répond pas à la question posée (« indépendamment de l'orientation déjà recommandée »).
- Il n'existe **aucune étiquette « profil »** dans les données : les profils (fragile, intermédiaire, solide) ne sont pas des catégories prédéfinies mais des regroupements à **découvrir**. C'est exactement la définition de l'apprentissage non supervisé.
- Le **K-Means** est retenu car les deux variables (**Notes**, **Assiduité**) sont quantitatives, les groupes attendus sont de forme approximativement convexe (visibles sur le nuage de points de la Q2), et K-Means est simple à interpréter pour un public non statisticien (un centroïde = un profil moyen).

```
1 features = df[["Notes", "Assiduite"]]  
2 X_scaled = StandardScaler().fit_transform(features) # indispensable  
3 kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)  
4 df["cluster"] = kmeans.fit_predict(X_scaled)
```

La standardisation est indispensable : sans elle, l'assiduité (échelle 0–100) dominerait le calcul des distances et écraserait la contribution des notes (échelle 0–20).

5.3 Choix du nombre de clusters K




Figure 5: Méthode du coude (inertie) et score de silhouette

K	Inertie	Silhouette
2	487,4	0,627
3	231,8	0,567
4	137,2	0,534
5	89,3	0,524

Tableau 5: Résultats recalculés (graine 1292)

Discussion honnête du choix de K : le score de silhouette est en réalité **maximal pour K=2** (0,627), ce qui indiquerait mathématiquement que 2 groupes séparent le mieux les données (probablement une simple coupure « faible / forte performance »). Nous retenons néanmoins **K=3**, pour deux raisons : (1) la baisse d’inertie entre K=2 et K=3 reste très importante (487 → 232, soit −52%), signe qu’un découpage plus fin capture une structure réelle et pas seulement du bruit ; (2) sur le plan **pédagogique**, 3 groupes (fragile / intermédiaire / solide) sont plus actionnables pour le conseil pédagogique qu’une simple dichotomie « en difficulté / pas en difficulté ». Ce choix est un compromis assumé entre optimalité statistique stricte et utilité opérationnelle – limite qu’il convient de signaler clairement au proviseur.

5.4 Résultats – 3 profils

Cluster	Note moy. (/20)	Assiduité moy. (%)	Effectif	Profil
0	16,4	82,2	363	Solide
1	3,1	16,3	329	Fragile
2	9,5	47,7	308	Intermédiaire

Tableau 6: Profils identifiés (données recalculées, graine 1292)




Figure 6: Visualisation des 3 clusters (les croix rouges sont les centroïdes)

- **Profil fragile** (329 élèves, 32,9%) : note et assiduité très basses ⇒ accompagnement renforcé, tutorat, suivi de l’absentéisme.

- **Profil intermédiaire** (308 élèves, 30,8%) : résultats moyens $\Rightarrow$ consolidation des acquis, objectifs progressifs.
- **Profil solide** (363 élèves, 36,3%) : bonne assiduité et bons résultats $\Rightarrow$ maintien, approfondissement, filières exigeantes.

5.5 Limites et discussion

- Le clustering **décrit** des profils de performance, il ne **prescrit** pas une filière : la correspondance profil $\leftrightarrow$ orientation n'est qu'une lecture a posteriori, non garantie.
- Le choix $K=3$ reste, comme discuté ci-dessus, un compromis et non un optimum statistique strict ($K=2$ obtient une meilleure silhouette).
- K-Means suppose des clusters de forme sphérique dans l'espace standardisé ; une structure plus complexe (non convexe) serait mal capturée par cette méthode.

6 Question 4 – Suggestion automatique d'orientation

6.1 Question posée

« Pour les prochaines années, j'aimerais qu'un système puisse suggérer automatiquement une orientation (scientifique/littéraire) pour un nouvel élève, à partir de ses deux mesures, avant la délibération du conseil de classe. Est-ce raisonnable ? Quelle confiance, quel risque pédagogique ? »

6.2 Pourquoi l'apprentissage *supervisé* ici (contraste avec Q3)

Contrairement à la question 3, on dispose ici d'une **étiquette cible connue et exploitable** : **target** (l'orientation déjà recommandée par le conseil de classe pour les élèves passés). L'objectif est explicitement de **prédire cette étiquette** pour de nouveaux élèves : c'est la définition même d'un problème d'apprentissage supervisé, ici de **classification binaire** (et non de régression, car la cible est catégorielle : scientifique/littéraire).

6.3 Modèles comparés

Trois classifieurs sont comparés : la **régression logistique** (interprétable, donne une probabilité), un **arbre de décision** (règles lisibles par un non statisticien) et **KNN** (référence de proximité).

```

1 X_train, X_test, y_train, y_test = train_test_split(
2     X, y, test_size=0.2, random_state=42, stratify=y)
3
4 log_reg = LogisticRegression().fit(X_train_scaled, y_train)
5 arbre   = DecisionTreeClassifier(max_depth=4, random_state=42).fit(
6     X_train, y_train)
7 knn     = KNeighborsClassifier(n_neighbors=5).fit(X_train_scaled,
8     y_train)

```

6.4 Résultats

Modèle	Accuracy	Précision	Rappel	F1	AUC
Arbre de décision	0,995	1,000	0,990	0,995	0,995
KNN (k=5)	0,990	1,000	0,980	0,990	0,995
Régression logistique	0,985	1,000	0,970	0,985	0,999

Tableau 7: Comparaison des 3 classifieurs (jeu de test, n=200, graine 1292)




Figure 7: Matrice de confusion – Arbre de décision (101 vrais négatifs, 98 vrais positifs, 1 seule erreur sur 200)




Figure 8: Courbes ROC des 3 modèles

Validation croisée (5 blocs, régression logistique) : $F1 = 0,986 \pm 0,007$, confirmant que la performance n'est pas due au hasard du découpage train/test.

6.5 Est-ce raisonnable ? Quelle confiance et quel risque ?

Les scores sont excellents (99% de précision, AUC proche de 1), mais il faut immédiatement en relativiser la portée pour le prevoiseur :

1. **Ces performances quasi parfaites tiennent à la construction même du jeu de données** : dans nos données synthétiques, `target` a été défini comme un simple seuil sur l'assiduité (`target = 1 si Assiduité  $\geq$  50%`). Le modèle n'a donc, pour l'essentiel, qu'à retrouver ce seuil – ce qui est un problème beaucoup plus facile qu'une vraie décision d'orientation.
2. **Dans la réalité**, une décision d'orientation du conseil de classe repose sur bien plus que deux variables (bulletins complets, avis des professeurs de plusieurs matières, projet de l'élève, entretiens). Un modèle entraîné sur seulement 2 variables sous-estimerait cette richesse et **ne doit pas être considéré comme fiable au même niveau** sur des données réelles.
3. **Risque d'automatisation excessive** (« **automation bias** ») : un score affiché à 99% peut donner une fausse impression de certitude absolue et pousser à ne plus remettre en cause la suggestion automatique, y compris dans les cas limites (proche de la frontière de décision) où l'erreur est justement la plus probable.
4. **Risque d'effet de raccourci** : la frontière de décision apprise (ci-dessous) est quasiment une droite correspondant au seuil d'assiduité utilisé pour générer les données – un système réel pourrait de la même façon apprendre une règle biaisée si les décisions historiques du conseil de classe reflètent elles-mêmes des biais (origine sociale, établissement d'origine, etc.), que le modèle reproduirait alors aveuglément.




Figure 9: Frontière de décision apprise par la régression logistique

6.6 Recommandation

Oui, un système de suggestion automatique est techniquement réalisable, mais il doit rester un **outil d'aide à la décision**, pas un **système de décision** :

- afficher une **probabilité** plutôt qu'une décision binaire, pour laisser apparaître les cas incertains (proches de 50%) ;

- réserver l'intervention humaine systématique pour les cas où la probabilité est proche de la frontière de décision ;
- ne jamais utiliser le système **seul**, mais toujours en complément de l'avis du conseil de classe, en particulier tant que le modèle n'est validé que sur des données synthétiques à seulement 2 variables.

7 Synthèse pour le proviseur

Question	Réponse synthétique
Q1 – Répartition	Les notes se répartissent de façon relativement uniforme entre 0 et 20 (médiane 9,75/20). Aucun élève n'est statistiquement atypique selon la règle de Tukey. La boîte à moustaches est le support le plus lisible pour le conseil pédagogique.
Q2 – Lien et prédiction	Le lien assiduité/note est confirmé ($r = 0,986$). La régression linéaire, presque aussi précise qu'un modèle plus complexe (SVR) mais bien plus interprétable, permet d'estimer une note probable avec une erreur moyenne d'environ 1 point sur 20. En dessous du seuil de 2 points, l'anticipation est utilisable comme indication, jamais comme substitut à l'évaluation réelle.
Q3 – Profils	3 profils d'élèves émergent naturellement (sans utiliser l'orientation) : fragile (32,9%), intermédiaire (30,8%), solide (36,3%). Ces profils décrivent des situations scolaires et peuvent guider un accompagnement différencié, sans se substituer aux décisions d'orientation déjà prises.
Q4 – Suggestion automatique	Un modèle de classification atteint une précision très élevée (99%) sur nos données, mais ce résultat est en grande partie un artefact de la construction du jeu de données. Un tel système est envisageable comme aide à la décision (probabilité affichée, vigilance sur les cas proches de la frontière), mais présente un risque réel d'automatisation excessive s'il est utilisé seul, sans validation sur des données réelles et sans les autres éléments d'appréciation du conseil de classe.

Tableau 8: Synthèse des réponses aux quatre questions du proviseur

7.1 Recommandations générales

1. Ne jamais automatiser entièrement les décisions d'orientation : les modèles estiment et décrivent, ils ne remplacent pas le conseil de classe.
2. Croiser systématiquement les sources : notes, assiduité, contrôles continus, entretiens.
3. Utiliser les visualisations (boîte à moustaches, nuage de points, carte des clusters, courbe ROC) comme supports de discussion en réunion pédagogique plutôt que des tableaux de chiffres bruts.
4. Garantir la reproductibilité : l'ensemble des analyses est rejouable via `python main.py`, avec la graine corrigée 1292.